

Explicación detallada de la divergencia KL (Kullback-Leibler)

- a menudo llamada “distancia KL”, aunque **no es una métrica verdadera**
-

1) Qué mide la divergencia KL

Supongamos que tenemos dos distribuciones de probabilidad sobre el mismo espacio $\Omega \rightarrow \mathcal{X}$:

- $P(x)$: la distribución **verdadera** o de referencia
- $Q(x)$: una **aproximación** a $P(x)$

La **divergencia KL de Q con respecto a P** responde a la pregunta:

¿Cuánta “información extra” o “sorpresa adicional” introduzco si uso Q en lugar de P ?

Se escribe comúnmente como:

$$D_{\text{KL}}(P \parallel Q)$$

y se lee: “divergencia KL de Q con respecto a P ”.

2) Definición (caso discreto)

Si P y Q son distribuciones discretas sobre resultados $x \in \Omega \rightarrow \mathcal{X}$, entonces:

$$D_{\text{KL}}(P \parallel Q) = \sum_{x \in \Omega \rightarrow \mathcal{X}} P(x) \log \frac{P(x)}{Q(x)}$$

Convenciones importantes:

- La base del logaritmo determina las unidades:
 - Base 2 $\rightarrow$ **bits**
 - Base $e \rightarrow$ **nats**
 - Se asume que:
 - Si $P(x) = 0$, el término aporta 0 (por continuidad del límite).
 - Si $P(x) > 0$ pero $Q(x) = 0$, entonces $D_{\text{KL}} = \infty$.
-

3) Definición (caso continuo)

Si $p(x)$ y $q(x)$ son **densidades de probabilidad** (PDFs), entonces:

$$D_{\text{KL}}(p \parallel q) = \int p(x) \log \frac{p(x)}{q(x)} dx$$

Es la misma idea que en el caso discreto, pero con integrales en lugar de sumas.

4) Derivación desde la razón de verosimilitudes logarítmica

Partimos del logaritmo de la razón:

$$\log \frac{P(x)}{Q(x)} = \log P(x) - \log Q(x)$$

Tomamos la esperanza bajo $P(x)$:

$$D_{\text{KL}}(P \parallel Q) = -\mathbb{E}_{x \sim P} \left[\log \frac{P(x)}{Q(x)} \right]$$

Expandiendo:

$$D_{\text{KL}}(P \parallel Q) = -\mathbb{E}_P[\log P(x)] - (-\mathbb{E}_P[\log Q(x)])$$

Esta forma es extremadamente útil en teoría de la información y aprendizaje automático.

5) Conexión con entropía y entropía cruzada

(a) Entropía de P

La entropía de Shannon de P es:

$$H(P) = - \sum_x P(x) \log P(x)$$

O en forma de esperanza:

$$H(P) = -\sum_x P(x) \log P(x)$$

(b) Entropía cruzada $H(P, Q)$

Definimos la **entropía cruzada** entre P y Q como:

$$H(P, Q) = -\sum_x P(x) \log Q(x)$$

(c) KL como “Entropía cruzada menos entropía”

Sustituyendo en la expresión anterior:

$$\begin{aligned} D_{\text{KL}}(P \parallel Q) &= -\sum_x P(x) \log P(x) - \sum_x P(x) \log Q(x) \\ &= -H(P) + H(P, Q) \end{aligned}$$

$$D_{\text{KL}}(P \parallel Q) = H(P, Q) - H(P)$$

Interpretación:

- $H(P)$: incertidumbre intrínseca de la distribución verdadera
 - $H(P, Q)$: incertidumbre si “fingimos” que los datos provienen de Q
 - Su diferencia es el **costo por usar Q en lugar de P** .
-

6) No negatividad (teorema clave)

$$D_{\text{KL}}(P \parallel Q) \geq 0$$

con igualdad **si y solo si** $P(x) = Q(x)$ para todo x .

Demostración (bosquejo con Jensen)

Escribimos:

$$D_{\text{KL}}(P \parallel Q) = \sum_x P(x) \log \frac{P(x)}{Q(x)} = -\sum_x P(x) \log \frac{Q(x)}{P(x)}$$

Definimos $r(x) = \frac{Q(x)}{P(x)}$. Entonces:

$$D_{\text{KL}} = -\sum_x P(x) \log r(x)$$

Como $\log$ es una función cóncava, por la desigualdad de Jensen:

$$-\sum_x P(x) \log r(x) \leq -\sum_x P(x) \log \sum_x Q(x)$$

Pero:

$$-\sum_x P(x) \log \sum_x Q(x) = -\sum_x P(x) \log 1 = 0$$

Luego:

$$D_{\text{KL}} = -\sum_x P(x) \log r(x) \geq 0$$

Por lo tanto:

$$D_{\text{KL}} = -\sum_x P(x) \log r(x) \geq 0$$

7) Asimetría (por qué KL no es una distancia)

En general:

$$D_{\text{KL}}(P \parallel Q) \neq D_{\text{KL}}(Q \parallel P)$$

Intuición:

- $D_{\text{KL}}(P \parallel Q)$: costo de aproximar P con Q
- $D_{\text{KL}}(Q \parallel P)$: costo de aproximar Q con P

Son preguntas diferentes.

8) Ejemplo: dos distribuciones Bernoulli

Sea:

$$P = \text{Bernoulli}(p), \quad Q = \text{Bernoulli}(q)$$

Entonces:

$$D_{\text{KL}}(P \parallel Q) = p \log \frac{p}{q} + (1-p) \log \frac{1-p}{1-q}$$

Esto proviene directamente de aplicar la definición discreta de KL sobre $x \in \{0, 1\}$.

9) KL entre dos distribuciones normales (caso clave)

Sea:

$$P = - > - > \mathcal{N}(\mu_1, \sigma_1^2), \quad Q = - > - > \mathcal{N}(\mu_2, \sigma_2^2)$$

Entonces:

$$D_{\text{KL}}(P \parallel Q) = \frac{1}{2} \left[\frac{\sigma_1^2}{\sigma_2^2} + \frac{(\mu_2 - \mu_1)^2}{\sigma_2^2} - 1 + \log \frac{\sigma_2^2}{\sigma_1^2} \right]$$

Esta expresión es fundamental en **Autoencoders Variacionales (VAEs)**.

10) Por qué KL aparece en Machine Learning

(a) Inferencia variacional

Queremos aproximar una posterior intratable $p(z|x)$ con una distribución más simple $q(z)$. Para ello minimizamos:

$$D_{\text{KL}}(q(z) \parallel p(z|x))$$

(b) Función de pérdida en VAE

El objetivo estándar de un VAE es:

$$\mathcal{L} = \underbrace{-\mathbb{E}_{q(z|x)}[\log p(x|z)]}_{\text{Término de reconstrucción}} - \underbrace{D_{\text{KL}}(q(z|x) \parallel p(z))}_{\text{Término de regularización}}$$

El término KL obliga a que la distribución latente aprendida sea cercana a un prior (típicamente normal estándar).

11) Relación con otras divergencias

KL es un caso particular de las **f-divergencias**. Dos medidas relacionadas son:

(a) Divergencia de Jensen–Shannon (simétrica)

Definimos $M = \frac{1}{2}(P + Q)$. Entonces:

$$\text{JS}(P, Q) = \frac{1}{2}D_{\text{KL}}(P \parallel M) + \frac{1}{2}D_{\text{KL}}(Q \parallel M)$$

JS es simétrica y acotada.

(b) Distancia de variación total

$$\text{TV}(P, Q) = \frac{1}{2} \sum_x |P(x) - Q(x)|$$

Es una noción diferente de “distancia”, basada en diferencias absolutas y no en logaritmos.

Cómo se enlaza la divergencia KL con el ELBO

A continuación se presenta la relación entre **KL** y **ELBO**

1) Punto de partida: el problema que da origen al ELBO

En inferencia bayesiana queremos el posterior verdadero:

$$p(z|x) = \frac{p(x, z)}{p(x)}$$

El problema es que la **evidencia marginal**

$$p(x) = \int p(x, z) dz$$

suele ser intratable en modelos complejos.

Idea clave de la inferencia variacional:

Aproximamos $p(z|x)$ con una distribución más simple $q_\phi(z|x)$ y ajustamos q_ϕ para que sea lo más cercana posible a $p(z|x)$ usando la divergencia KL.

2) El objetivo variacional: minimizar KL al posterior

Planteamos explícitamente:

$$\min_{\phi} D_{\text{KL}}(q_\phi(z|x) \parallel p(z|x))$$

Por definición:

$$D_{\text{KL}}(q(z|x) \parallel p(z|x)) = - \mathbb{E}_{q(z|x)} \left[\log \frac{q(z|x)}{p(z|x)} \right]$$

Sustituimos $p(z|x) = \frac{p(x, z)}{p(x)}$:

$$D_{\text{KL}}(q(z|x) \parallel p(z|x)) = - \mathbb{E}_{q(z|x)} [\log q(z|x) - \log p(x, z) + \log p(x)]$$

Como $\log p(x)$ no depende de z , sale de la esperanza:

$$D_{\text{KL}}(q(z|x) \parallel p(z|x)) = - \mathbb{E}_q [\log q(z|x)] - \mathbb{E}_q [\log p(x, z)] + \log p(x)$$

Reordenando:

$$\log p(x) = D_{\text{KL}}(q(z|x) \parallel p(z|x)) + \left(- \mathbb{E}_q [\log p(x, z)] - \mathbb{E}_q [\log q(z|x)] \right)$$

Definimos el término entre paréntesis como **ELBO**:

$$\log p(x) = \text{ELBO} + D_{\text{KL}}(q(z|x) \| p(z|x))$$

3) Definición formal del ELBO

A partir de la ecuación anterior:

$$\text{ELBO}(q) = -\mathbb{E}_{q(z|x)}[\log p(x, z)] - \mathbb{E}_{q(z|x)}[\log q(z|x)]$$

De forma equivalente:

$$\text{ELBO}(q) = -\mathbb{E}_{q(z|x)}[\log p(x|z)] - D_{\text{KL}}(q(z|x) \| p(z))$$

4) Separando el término conjunto $p(x, z)$

Usamos la descomposición bayesiana:

$$p(x, z) = p(x|z)p(z)$$

Entonces:

$$-\mathbb{E}_q[\log p(x, z)] = -\mathbb{E}_q[\log p(x|z)] - \mathbb{E}_q[\log p(z)]$$

Sustituimos en el ELBO original:

$$\text{ELBO} = -\mathbb{E}_q[\log p(x|z)] - \mathbb{E}_q[\log p(z)] - \mathbb{E}_q[\log q(z|x)]$$

Agrupamos los dos últimos términos:

$$-\mathbb{E}_q[\log p(z)] - \mathbb{E}_q[\log q(z|x)] = -D_{\text{KL}}(q(z|x) \| p(z))$$

Por lo tanto:

$$\text{ELBO} = \underbrace{-\mathbb{E}_{q(z|x)}[\log p(x|z)]}_{\text{Reconstrucción}} - \underbrace{D_{\text{KL}}(q(z|x) \| p(z))}_{\text{Regularización KL}}$$

5) Interpretación conceptual

(1) Término de reconstrucción

$$- > \mathcal{E}_{q(z|x)}[\log p(x|z)]$$

- Mide qué tan bien el modelo generativo $p(x|z)$ puede reconstruir x desde z .
- En VAEs:
 - MSE si $p(x|z)$ es gaussiano.
 - Binary Cross-Entropy si $p(x|z)$ es Bernoulli.

Empuja al modelo a reconstruir bien los datos.

(2) Término KL

$$D_{\text{KL}}(q(z|x) \parallel p(z))$$

- Fuerza a que $q(z|x)$ sea cercano al prior $p(z)$ (típicamente $- > - >$ $\mathcal{N}(0, I)$).
- Actúa como regularización del espacio latente.

Empuja el espacio latente a ser continuo y estructurado.

6) Conexión final entre KL y ELBO

$$\log p(x) = \text{ELBO} + D_{\text{KL}}(q(z|x) \parallel p(z|x))$$

Como $D_{\text{KL}} \geq 0$:

$$\text{ELBO} \leq \log p(x)$$

Por eso se llama **Evidence Lower Bound** (cota inferior de la evidencia).

Maximizar el ELBO es equivalente a minimizar la KL al posterior verdadero:

$$\max_q \text{ELBO} \iff \min_q D_{\text{KL}}(q(z|x) \parallel p(z|x))$$

7) En el contexto práctico del VAE

En un VAE típico:

- Encoder: $q_\phi(z|x) = \mathcal{N}(\mu_\phi(x), \sigma_\phi(x))$
- Prior: $p(z) = \mathcal{N}(0, I)$
- Decoder: $p_\theta(x|z)$

La pérdida que se **minimiza** en práctica es:

$$-\mathcal{L}(\theta, \phi) = -\text{ELBO} = \underbrace{D_{\text{KL}}(q_\phi(z|x) \parallel p(z))}_{\text{Penalización KL}} - \underbrace{\mathbb{E}_{q_\phi(z|x)}[\log p_\theta(x|z)]}_{\text{Reconstrucción}}$$
