Entrenamiento de Redes Neuronales

Cesar Garcia

2025

Objetivos de la sesión

- Comprender qué significa entrenar una red neuronal.
- Entender el rol de las funciones de pérdida.
- Explicar el concepto de descenso de gradiente de forma intuitiva.
- Introducir épocas, iteraciones y procesamiento por lotes (batches).

Mapa mental del entrenamiento

Entrenar una red neuronal es un **proceso cíclico**:

1. Propagación hacia adelante (forward)
2. Cálculo de la pérdida
3. Cálculo del gradiente
4. Actualización de pesos
5. Repetir durante múltiples épocas

Este ciclo es la base de **todo entrenamiento moderno** de redes neuronales.

¿Qué significa entrenar una red?

Intuición general

Entrenar una red neuronal significa **ajustar los pesos** para mejorar las predicciones.

Proceso

1. La red hace una predicción con pesos iniciales aleatorios.
2. Se compara la predicción con el valor real.
3. Se calcula un error (pérdida).
4. Se ajustan los pesos para reducir ese error.

Funciones de Pérdida

¿Qué es una función de pérdida?

- Mide qué tan mala es una predicción.
- El entrenamiento busca **minimizar** esta cantidad.
- No hay aprendizaje sin una función de pérdida.
- Diferentes tareas requieren diferentes funciones de pérdida.

Relación entre problema, activación y pérdida

Problema	Activación de salida	Función de pérdida
Regresión	Lineal	MSE / MAE
Clasificación binaria	Sigmoid	Binary Cross Entropy
Clasificación multiclase	Softmax	Categorical Cross Entropy

La pérdida **no se elige arbitrariamente**: depende del tipo de salida.

Funciones de pérdida para Regresión

Error Cuadrático Medio — MSE

Definición:

Mide la distancia cuadrática entre predicciones y valores reales.

Penaliza fuertemente errores grandes.

Fórmula:

$$\text{MSE} = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2$$

Intuición: - La curva es suave y diferenciable.

- Los errores grandes pesan más $\rightarrow$ puede ser sensible a outliers.

Visualizacion

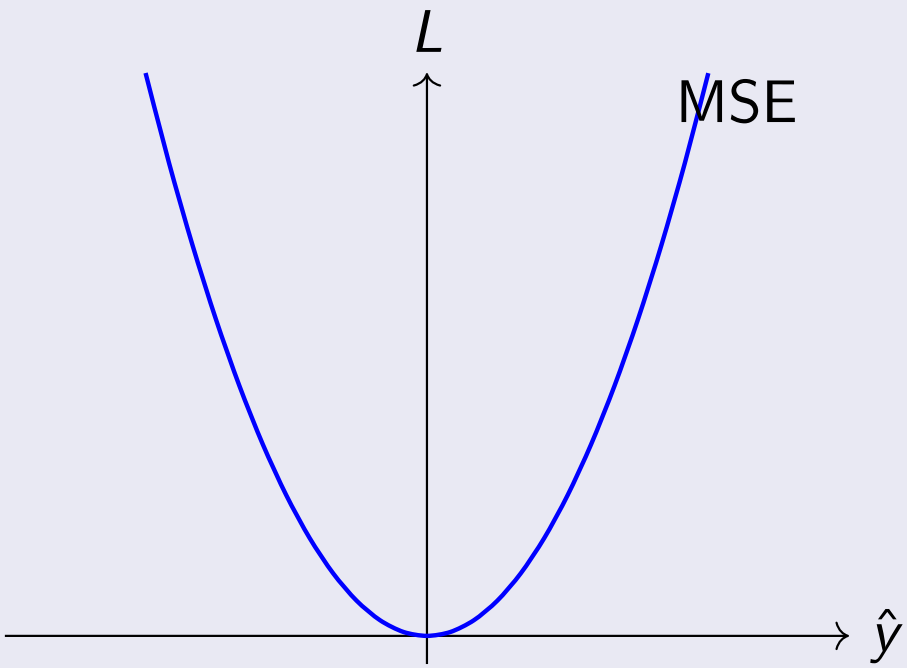

Error Absoluto Medio — MAE

Definición:
Suma las diferencias absolutas entre predicción y realidad.
Fórmula:

$$\text{MAE} = \frac{1}{n}\sum_{i=1}^{n}|y_i - \hat{y}_i|$$

Intuición: - Penaliza todos los errores de manera proporcional.
- Más robusto frente a *outliers*.
- No es diferenciable en 0 (pero frameworks lo manejan bien).

Visualizacion

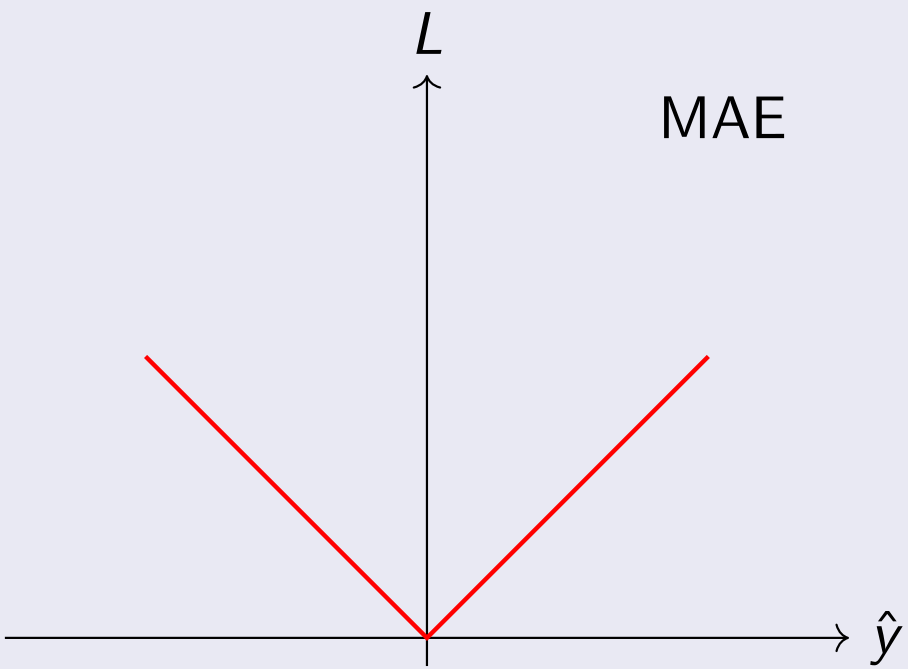

Funciones de pérdida para Clasificación

Entropía Cruzada — Binary Cross Entropy (BCE)

Usada en:

- Clasificación binaria
- Redes con una salida sigmoide

Fórmula:

$$\text{BCE} = -\left[y \log(\hat{y}) + (1 - y) \log(1 - \hat{y})\right]$$

Intuición: - Si la predicción es incorrecta y con mucha confianza, la pérdida es *muy grande*.

- Esto acelera el aprendizaje.
- Es equivalente a maximizar la verosimilitud de una distribución Bernoulli.

Visualizacion: (pérdida para y = 1)

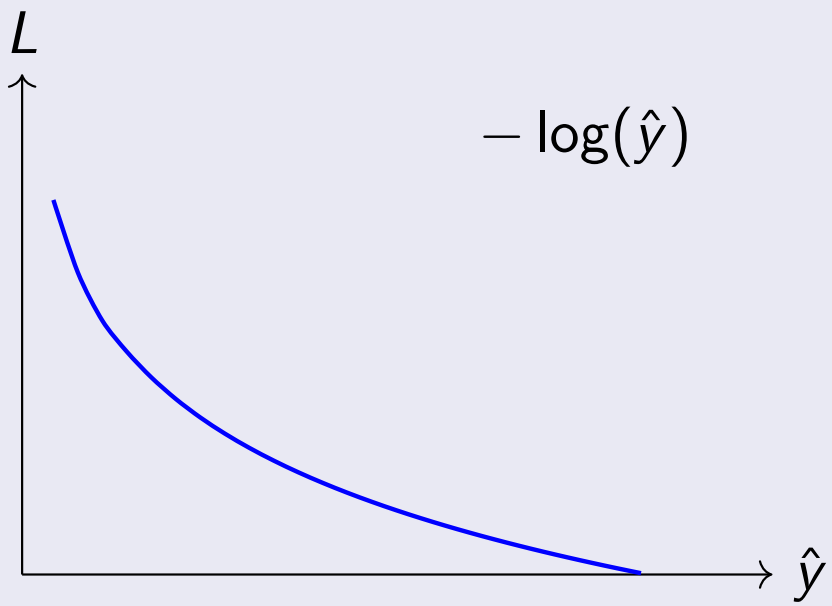

Entropía Cruzada Categórica — CCE

Para:

- Problemas multiclase (Softmax)

Fórmula:

$$\text{CCE} = -\sum_{c=1}^{C} y_c \log(\hat{y}_c)$$

Donde:

- y_c es 1 si la clase verdadera es c, 0 en otro caso (one-hot encoding).
- $\hat{y}_c$ es la probabilidad softmax de la clase c.

Intuición: - Obliga al modelo a asignar alta probabilidad a la clase correcta.

- Muy usada en visión por computadora y NLP.

Descenso de Gradiente (Gradient Descent)

Intuición

- Imagina una montaña donde el objetivo es llegar al punto más bajo.
- El gradiente indica en qué dirección sube más rápido la montaña.
- Para minimizar el error, tomamos pasos hacia la dirección opuesta.

Idea central

Actualizar los pesos con pequeños pasos que reduzcan la pérdida.

Visualización

- gradient descent

Importancia de las derivadas en redes neuronales

Idea clave

Las derivadas nos indican **qué tan sensible es el error del modelo** a pequeños cambios en sus parámetros (pesos y sesgos).
En otras palabras, responden a la pregunta:

"Si cambio un peso un poco, ¿el error mejora o empeora, y cuánto?"

Sin derivadas no hay forma sistemática de saber **cómo ajustar los pesos**, por lo tanto **no hay aprendizaje**.

¿Dónde aparecen las derivadas?

En cada neurona ocurren dos pasos fundamentales:

1. **Combinación lineal**

$$z = Wx + b$$

2. **Función de activación**

$$a = f(z)$$

Para poder entrenar la red necesitamos saber:

- Cómo cambia la activación cuando cambia z
- Cómo cambia z cuando cambian los pesos

Esto se expresa mediante derivadas locales:

$$\frac{\partial a}{\partial z} = f'(z) \qquad \text{(derivada de la activación)}$$

$$\frac{\partial z}{\partial W} = x \qquad \text{(cómo el peso afecta al valor interno)}$$

Estas derivadas **no optimizan nada por sí solas**, pero son los bloques básicos que permiten calcular el gradiente del error.

Derivadas y aprendizaje

El entrenamiento de una red neuronal funciona porque:

- La función de pérdida mide el error.
- Las derivadas indican **en qué dirección cambia ese error**.
- El descenso de gradiente ajusta los pesos en la dirección que **reduce la pérdida**.

Conceptualmente:

Derivadas grandes $\rightarrow$ *el aprendizaje avanza rápido*

Derivadas cercanas a cero $\rightarrow$ *el aprendizaje se vuelve lento o se detiene*

Importancia de las funciones de activación

Las funciones de activación no solo introducen no linealidad, también determinan **cómo se propaga el gradiente hacia atrás**.

- **Sigmoid y Tanh**
  - Se "aplanan" para valores grandes o pequeños.
  - Sus derivadas se vuelven muy pequeñas.
  - Pueden causar el problema de **vanishing gradient**.
- **ReLU, GELU, ELU, Swish**
  - Mantienen derivadas útiles en gran parte del dominio.
  - Permiten entrenar redes profundas de forma estable.
  - Son preferidas en arquitecturas modernas.

Qué **no** necesitamos calcular a mano

- No calculamos derivadas completas de la función de pérdida a mano.
- Frameworks modernos (TensorFlow, PyTorch) lo hacen automáticamente.
- Lo importante es entender:
  - **Qué papel juegan las derivadas**
  - **Por qué ciertas activaciones funcionan mejor que otras**

Más adelante veremos cómo estas ideas se organizan en el algoritmo de **propagación hacia atrás (backpropagation)**.

Mensaje final

Las derivadas son el **mecanismo interno del aprendizaje** en redes neuronales.

No son un fin matemático en sí mismas, sino la herramienta que permite:

convertir el error en información útil para mejorar el modelo.

Variantes del Descenso de Gradiente

Batch Gradient Descent

Usa **todos los datos** en cada actualización.

Stochastic Gradient Descent (SGD)

Usa **un solo dato** por actualización.

Mini-Batch Gradient Descent

Usa pequeños grupos de datos:
- Más estable que SGD
- Más rápido que batch completo
- El método más utilizado

Learning Rate

Concepto

El learning rate define el tamaño del paso durante el descenso de gradiente.

Comportamiento

- Muy grande $\rightarrow$ el modelo salta el mínimo.
- Muy pequeño $\rightarrow$ entrenamiento lento.

Épocas, Iteraciones y Batches

Época

Una pasada completa por todos los datos.

Batch

Un subconjunto de los datos.

Iteración

Una actualización de pesos por cada batch.

Importancia

- Controlan la estabilidad y velocidad del aprendizaje.
- Permiten generalizar mejor sin sobreajustar.

Procesamiento por Lotes (Batch Processing)

Beneficios

- Estabiliza el cálculo del gradiente.
- Reduce ruido en la actualización.
- Optimiza el uso del hardware (GPU/CPU).