

Bucles de Entrenamiento y Evaluación de Modelos

Cómo entrenar correctamente una red neuronal

Cesar Garcia

2025

- Entender **qué hace realmente** un bucle de entrenamiento
- Diferenciar claramente **entrenamiento** y **evaluación**
- Comprender épocas, batches e iteraciones
- Introducir validación como herramienta de diagnóstico
- Detectar sobreajuste y subajuste en la práctica

¿Qué parte del entrenamiento te parece más confusa: el código o el proceso?

El entrenamiento como proceso

Idea central

Entrenar una red neuronal **no es una sola operación**.

Es un proceso repetitivo que:

- calcula predicciones
- mide errores
- ajusta parámetros
- evalúa comportamiento

Todo esto ocurre siguiendo **reglas muy estrictas**.

¿Qué pasaría si ajustáramos los pesos usando los datos de validación?

Épocas, batches e iteraciones

Tres escalas distintas

- **Batch:** subconjunto de datos
- **Iteración:** un forward + backward sobre un batch
- **Época:** pasar por todo el dataset una vez

Relación:

1 época = muchos batches = muchas iteraciones

¿Por qué no usamos todo el dataset en una sola iteración?

¿Por qué usar batches?

Motivación práctica

Usar batches permite:

- entrenar con datasets grandes
- introducir ruido útil en el gradiente
- mejorar eficiencia computacional

El gradiente por batch es:

- una **aproximación** del gradiente real
- suficiente para aprender

¿Qué efecto tendría usar un batch demasiado pequeño o demasiado grande?

Batch pequeño	Batch grande
Gradiente ruidoso	Gradiente estable
Más exploración	Menos exploración

Entrenamiento vs inferencia

Dos modos distintos

Durante **entrenamiento**:

- se calculan gradientes
- se actualizan parámetros
- algunas capas se comportan distinto

Durante **inferencia**:

- no se ajustan pesos
- solo se hacen predicciones

En PyTorch esto se refleja en:

- `model.train()`
- `model.eval()`

¿Por qué una red debería comportarse distinto al entrenar que al predecir?

Estructura mínima

Un bucle típico incluye:

- 1 Obtener un batch de datos
- 2 Forward pass
- 3 Calcular la pérdida
- 4 Backward pass
- 5 Actualizar parámetros
- 6 Reiniciar gradientes

Nada más. Nada menos.

¿Qué paso rompería el entrenamiento si lo olvidamos?

El bucle de validación

Propósito distinto

La validación sirve para:

- medir generalización
- detectar sobreajuste
- comparar modelos

Características clave:

- **no** se actualizan pesos
- **no** se calculan gradientes
- se usan datos no vistos

¿Por qué la validación no debe influir en el entrenamiento directamente?

No son lo mismo

- **Pérdida:**
 - señal de entrenamiento
 - optimizable
 - diferenciable
- **Métricas (accuracy, etc.):**
 - interpretación humana
 - no optimizables directamente

Entrenamos con pérdida. Evaluamos con métricas.

¿Por qué no entrenamos directamente usando accuracy?

Mirar curvas, no números

Observar:

- pérdida de entrenamiento
- pérdida de validación
- su relación en el tiempo

Patrones importan más que valores absolutos.

¿Qué información aporta la forma de la curva que no da un solo número?

Señales claras

Sobreajuste ocurre cuando:

- pérdida de entrenamiento ↓
- pérdida de validación ↑

El modelo memoriza, no generaliza.

¿Entrenar más tiempo siempre empeora el sobreajuste?

Capacidad insuficiente

Subajuste ocurre cuando:

- pérdida de entrenamiento alta
- pérdida de validación alta

El modelo no aprende el patrón.

¿Qué es más efectivo aquí: más datos o un modelo más complejo?

Qué evitar

- Mezclar entrenamiento y validación
- Mirar solo accuracy
- No reiniciar gradientes
- Cambiar demasiadas cosas a la vez
- Sacar conclusiones con pocas épocas

¿Cuál de estos errores crees que es más fácil de cometer?

Disciplina antes que complejidad

Un buen entrenamiento:

- es repetible
- es limpio
- es diagnosticable

Antes de arquitecturas modernas:

aprende a entrenar bien modelos simples.

¿Qué parte del bucle de entrenamiento te parece más frágil ahora?